LABORATUVAR 7 · PAKETPRO 3000 · Paketleme Makinesi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   (VMGS'ye YZ kamera eklenirse: 'bölge boş' dedi ama el var.) Sistem yalnız YZ'ye güvenmez: bağımsız emniyet katmanı (kafes kilidi, koruyucu cihaz, kasıtlı pedal onayı) kesmeyi engeller; ikinci kontrol ve operatör onayı (human override) vardır, YZ yalnızca ek uyarı verir.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Kamera sağlık kontrolü (donma, kare sürekliliği, parlaklık), ikinci sensörle çapraz doğrulama ve bütünlük korumalı veri hattı ile fark edilir. Şüpheli girdide fail-safe: kesme başlamaz/durur, alarm verilir, olay kaydedilir; insan onayı olmadan devam edilmez.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik risk analizi ve pilot verisiyle belirlenir (örn. ≥ 0.95; doğrulanmalı). Altında otomatik izin yok: dur, insana sor (human override) veya donanımsal/manuel emniyet moduna geç (fallback); her düşüş izlenir ve kaydedilir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol + human override: bağımsız kafes kilidi/koruyucu cihaz kesmeyi engeller; YZ yalnızca uyarır (Prediction ≠ Safety).
Girdi manipüle edildi	Monitoring + fail-safe: girdi sağlığı ve çapraz doğrulama; şüphede bıçak hareketi başlamaz/durur, alarm ve kayıt.
Confidence düştü	Confidence threshold + fallback: eşik altında dur / insana sor; manuel veya donanımsal emniyet moduna geç.

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.