LABORATUVAR 7 · GENEL SÜRÜM · Şişeleme Hattı

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Sistem YZ'ye körü körüne güvenmez: robot parametresi güvenli sınırlar içinde kalır (parametre doğrulaması), ikinci kontrol (ayrı sensör/örnekleme) ve gerekirse insan onayı (human override) vardır. Safety fonksiyonu (ışık perdesi, E-stop, STO) YZ'den bağımsızdır; YZ yanılsa da insan korunur.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Kamera sağlık kontrolü (donma, kare sürekliliği, parlaklık), ikinci sensörle çapraz doğrulama ve veri hattı bütünlüğü/monitoring ile fark edilir. Şüpheli girdide fail-safe: parametre güncellenmez (son güvenli değer), robot yavaş/güvenli moda geçer veya durur, alarm ve kayıt oluşur, insana sorulur.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik risk analizi ve pilot verisiyle belirlenir (örn. ≥ 0.95; doğrulanmalı). Altında otomatik karar yok: son güvenli parametre/yavaş mod, insana sor (human override), gerekirse dur (fallback); her düşüş izlenir ve kaydedilir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol + human override: parametre sınırları ve bağımsız safety yolu; YZ yalnızca öneri verir (Prediction ≠ Safety).
Girdi manipüle edildi	Monitoring + fail-safe: girdi sağlığı ve çapraz doğrulama; şüphede son güvenli değer/yavaş mod veya dur, alarm ve kayıt.
Confidence düştü	Confidence threshold + fallback: eşik altında dur / insana sor; güvenli parametre veya manuel moda geç.

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.